TÓPICOS ESPECIAIS EM REDES E SISTEMAS DISTRIBUÍDOS: PROGRAMAÇÃO PARALELA 2017.01



TÓPICOS ESPECIAIS EM REDES E SISTEMAS DISTRIBUÍDOS: PROGRAMAÇÃO PARALELA

Corretude na programação paralela

Slides baseados em:

Mary Hall, <u>CS 4230 - Parallel Programming</u>, University of Utah.

Capítulo 1 livro: Pacheco, Structured Parallel Programming: Arch Robison, James Reinders, and Michael McCool

Histórias

Estado de um programa concorrente: valores das variáveis do programa.

Processos executam sequencias de instruções.

Instruções estão compostas por uma sequência de ações atômicas: ações indivisíveis que examinam ou mudam o estado (s_i) do programa.

Durante a execução do programa essas sequencias de ações atômicas são intercaladas.

História (trace): Execução particular de um programa concorrente: $s_0 \rightarrow s_1 \rightarrow ... \rightarrow s_n$

(Onde s. é o estado do programa, a uma ação atômica) Conjunto de todas as histórias possíveis: (np)!/(n!)p

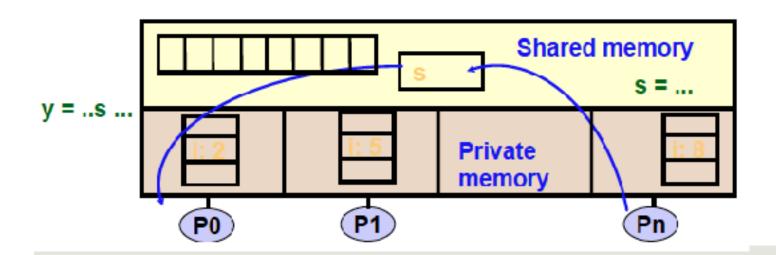
Programando Arquiteturas de memória compartilhada

Um programa de memória compartilhada é um conjunto de threads de controle. Threads são criadas no início do programa ou, eventualmente, de forma dinâmica.

Cada segmento tem:

- variáveis privadas, por exemplo, variáveis de pilha locais
- um conjunto de variáveis compartilhadas, por exemplo, variáveis estáticas, blocos comuns compartilhados, ou o heap global.

Threads se comunicam implicitamente escrevendo e lendo variáveis compartilhadas, e se coordenam através de construções de sincronização.



Como escrever programas paralelos

- Paralelismo de Tarefas
 - Particiona as tarefas entre os cores para resolver o problema.

- Paralelismo de Dados
 - ■Particiona os dados entre os cores para resolver o problema.
 - □ Cada core executa operações similares em sua porção dos dados.

Professor P

3 questões300 exames



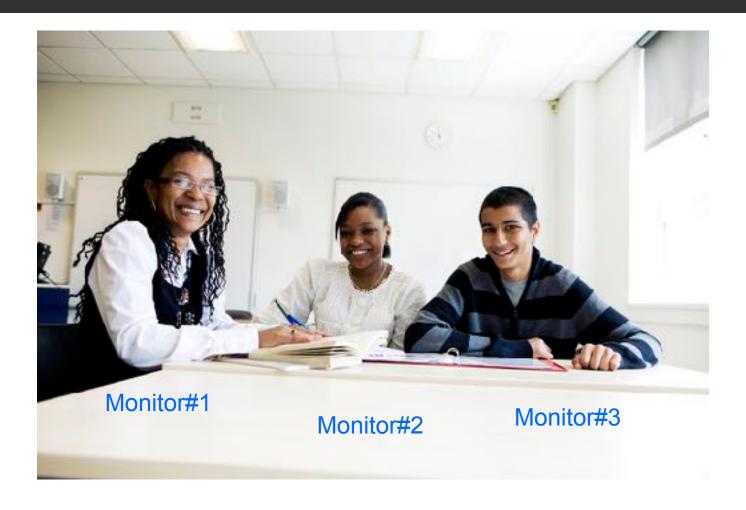


08/23/2012

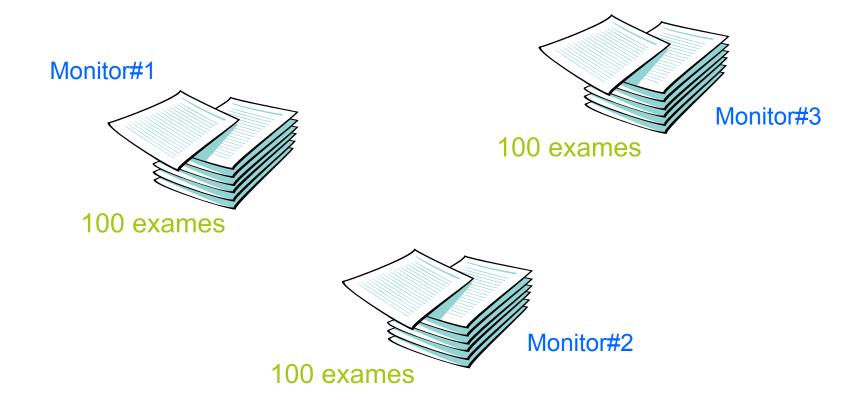
CS4230

08/23/2012

Monitores do Professor P



Divisão de trabalho:paralelismo de dados



Divisão de trabalho: paralelismo de tarefas

Monitor#1



Questão 2

Monitor#3

Questão 1



Questão 3 Monitor#2

Princípios de Computação Paralela

- Encontrar paralelismo suficiente (Lei de Amdahl)
- Granularidade quão grande deve ser cada tarefa paralela
- Localidade movimentação de dados custa mais do que aritmética
- Balanceamento de carga Não quero que 1K processadores esperem por um proc lento
- Coordenação e sincronização compartilhamento de dados com segurança
- Modelagem de desempenho / depuração / tuning



Todas estas coisas tornam a programação paralela ainda mais difícil do que a programação sequencial.

Cache e latência

- Memória que pode ser acessada mais rapidamente que a memória principal. Como preencher a cache?
- Localidade: O princípio que acessar uma posição é normalmente seguido pelo acesso a posição vizinha.
- Depois de acessar uma posição de memória (instrução ou dados), um programa irá tipicamente acessar a posição vizinha (localidade espacial) em um futuro próximo (localidade temporal).

Cache

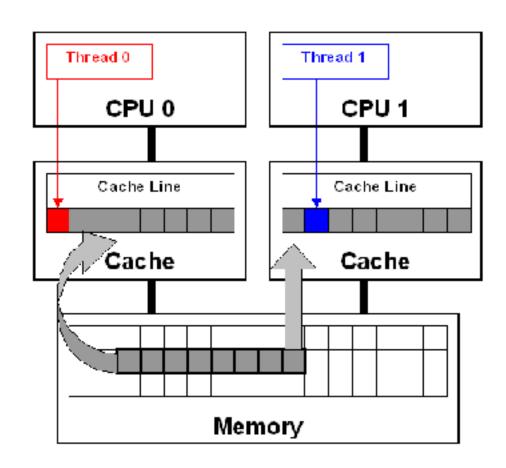
- Explorar localidade: Faz sentido o acesso a memória operar em blocos de dados em lugar de dados individuais, ex. arrays são alocados em posições contiguas de memória;
- □Blocos ou linhas de cache: assumindo linhas de 16 floats: z[0], z[1],...,z[15] estão na mesma linha.

Cache

- □ False Sharing: Ocorre quando duas variáveis não relacionadas (usadas por processos diferentes) são colocadas na mesma unidade de compartilhamento (página, linha de cache, etc). O comportamento das threads a respeito do acesso a memória se corresponde ao acesso a variáveis compartilhadas, ainda que não sejam.
- Qual deve ser o comportamento quando uma variável compartilhada armazenada no cache é modificada por outra thread?
- Invalidação!

Coerencia de cache

- CPU0 escreve na cache. O valor na cache e na mem principal são inconsistentes
- Linha de cache é invalidada e deve ser substituída com uma nova linha da memória



False Sharing

```
int i, j, m, n; double y[m];
/* Assign y = 0 */ ...
for (i = 0; i < m; i++)
    for (j = 0; j < n; j++)
        y[i] += f(i,j);</pre>
```

False Sharing

```
/* Variáveis privadas*/ int i, j, iter_count;
/* Variáveis compartilhadas inicializadas por 1 core */
int m, n, core_count; double y[m];
Iter count = m/core count ;
/* Core 0 faz */
for (i = 0; i < iter_count; i++)
      for (j = 0; j < n; j++)
             V[i] += f(i,j);
/* Core 1 faz */
for (i = iter_count; i < 2*iter_count; i++)</pre>
      for (j = 0; j < n; j++)
y[i] += f(i,j);</pre>
```

False Sharing

- Assumindo: 2 cores, m = 8, double = 8 bytes, cache lines = 64 bytes, 0 e 1 executam simultaneamente y[i] += f(i,j), y[0] está armazenado no inicio de uma linha de cache
- Uma linha de cache pode armazenar 8 doubles, y ocupa uma linha inteira;
- □ A atualização de y[i] invalida uma linha inteira de cache, o outro core precisará buscar a linha atualizada na memória ainda que estejam acessando elementos diferentes;
- Boa parte dos acessos serão a memória principal!
- Os resultados são corretos mas o desempenho é muito ruim.

Desempenho na mult de matrizes

/* Fth_mat_vect */

```
E = \frac{S}{t} = \frac{\left(\frac{T_{\text{serial}}}{T_{\text{parallel}}}\right)}{t} = \frac{T_{\text{serial}}}{t \times T_{\text{parallel}}}
    void *Pth_mat_vect(void* rank) {
        long my_rank = (long) rank;
       int i, j:
        int local_m = m/thread_count;
        int my_first_row = my_rank*local_m:
        int my_l ast_row = (my_lrank+1)*local_m - 1;
         for (i = my_first_row; i <= my_last_row; i++) {</pre>
            v[1] = 0.0:
9
            for (j = 0; j \le n; j++)
10
                 y[i] += A[i][j]*x[j]:
12
13
         return NULL:
```

Table 4.5 Run-Times and Efficiencies of Matrix-Vector Multiplication (times are in seconds)

	Matrix Dimension					
	$\pmb{8,000,000\times8}$		8000×8000		$8\times8,000,000$	
Threads	Time	Eff.	Time	Eff.	Time	Eff.
1 2 4	0.393 0.217 0.139	1.000 0.906 0.707	0.345 0.188 0.115	0.918	0.441 0.300 0.388	1.000 0.735 0.290

False Sharing: como resolvê-lo

- Padding: Encher o final do vetor com espaços. Garantir que a atualização em uma thread não afete a linha de cache de outra thread.
- Cada thread pode usar armazenamento local durante o laço e ao terminar atualizar o armazenamento compartilhado.
- Detecção: Intel Vtune Performance Analyzer
- int arr[PARALLEL * 16] __attribute__ ((aligned (8))); (http://stackoverflow.com/questions/18236603/cache-lines-false-sharing-and-alignment)
- Quando o código é compilado com opções de otimização, o compilador elimina false sharing usando variáveis temporais privadas à thread. Run-time false sharing poderia ser um problema se na hora da compilação a otimização for inabilitada.

